INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO (ESCOM)

Ingeniería en Inteligencia Artificial

Optimización bayesiana de redes neuronales para la decodificación de movimientos de los dedos a partir de señales electrocorticográficas

Defensa de Trabajo Terminal II | Registro Oficial: **2026-B145**

Autores que Presentan

- Saul Rodas Bautista
- Joel Valencia San Roman

Directores del Trabajo Terminal

- Dra. Miriam Pescador Rojas
- M.C. Miguel Abel León Hernández

Problemática del Proyecto

Variabilidad inter-sujeto, costo computacional y decodificación cinemática continua [1]

Calidad de Señales y Tarea Motora

El desarrollo de interfaces cerebro-computadora de alta precisión depende de la calidad de las señales capturadas y de la capacidad de interpretar los patrones neuronales asociados al movimiento. En este estudio, se utilizan señales de electrocorticografía (ECoG) del Data Set 4 de la BCI Competition IV, las cuales permiten estudiar la relación entre la actividad cerebral y las trayectorias continuas de flexión de los dedos [1].

Variabilidad Inter-Sujeto y Redes Profundas

Uno de los principales desafíos en el procesamiento de estas señales es la diferencia en la cantidad de canales y en la ubicación de los electrodos entre sujetos. Esta variabilidad dificulta la construcción de un modelo de aprendizaje preciso para todos los casos. Para interpretar estas señales complejas, las redes neuronales profundas representan una herramienta útil; no obstante, su eficacia depende en gran medida de la configuración de su arquitectura y de sus hiperparámetros.

Costo Computacional y Optimización Bayesiana

Al explorar diferentes combinaciones posibles, se requiere una capacidad computacional considerable, ya que cada configuración puede necesitar un nuevo entrenamiento. Incluso con otros métodos de búsqueda, como los algoritmos bioinspirados, este proceso puede resultar complejo y costoso. Por ello, surge la necesidad de estudiar la optimización bayesiana como una alternativa para realizar una búsqueda inteligente, basada en modelos probabilísticos, dentro del espacio de configuraciones de la red neuronal.

Problema Central y Propuesta de Solución

El problema central reside en determinar qué configuraciones de arquitectura e hiperparámetros permiten obtener una mayor precisión en la predicción de las trayectorias continuas de flexión de los dedos, considerando las diferencias entre los datos de cada sujeto. Para ello, se propone desarrollar un marco de configuración basado en redes neuronales profundas y optimización bayesiana, cuyo desempeño será evaluado mediante la correlación entre los movimientos predichos y los reales, y comparado con el modelo base y con los resultados reportados en la literatura.

Objetivo General, Objetivos Particulares y Propuesta de Solución

Objetivo General

Desarrollar un marco de configuración basado en redes neuronales profundas para la decodificación continua de movimientos de dedos a partir de señales electrocorticográficas del Dataset 4 de la BCI Competition IV, optimizando su arquitectura e hiperparámetros mediante optimización bayesiana y comparando su desempeño frente al modelo base y al estado del arte.

Objetivo Particular 1

Implementar una metodología de filtrado, segmentación, normalización y extracción espectral libre de fuga de información temporal.

Objetivo Particular 2

Integrar el flujo continuo de modelado diseñando una arquitectura base y su evolución estructural para predecir trayectorias de flexión.

Objetivo Particular 3

Diseñar e implementar con Optuna un esquema de optimización bayesiana para buscar automáticamente arquitecturas e hiperparámetros por sujeto.

Objetivo Particular 4

Comparar el modelo optimizado frente al modelo base y al estado del arte bajo condiciones auditables.

Sujeto	Canales Válidos	Desarrollo (CV)	Prueba Oficial	Condición Anatómica y Relación Señal-Ruido
Sujeto 1 (S1)	61 electrodos	400 s (5 bloques)	200 s	Cobertura fronto-parietal estándar con acoplamiento moderado entre dedos.
Sujeto 2 (S2)	46 electrodos	400 s (5 bloques)	200 s	Menor densidad espacial de rejilla y menor relación señal-ruido basal.
Sujeto 3 (S3)	63 electrodos	400 s (5 bloques)	200 s	Cobertura densa sobre el giro precentral (M1) con alta selectividad motora.

Fuente: Creación propia a partir de [1, 3] y el repositorio GitHub [21].

Enfoque TT2: Rediseño Arquitectónico (A1–A5) ▪ Optuna **TPE** ▪ 723 Entrenamientos Verificados

Procedimiento de Validación: División en Cinco Bloques

Partición cronológica con zona de purga para impedir fuga de información temporal [8, 21]

Esquema de Validación Cruzada ($K = 5$)

- **Cinco bloques cronológicos (B1–B5):** Los 400 s de desarrollo se dividen en 5 bloques contiguos de $N = 7750$ muestras válidas a 100 Hz cada uno.
- **Rotación de pliegues:** En cada pliegue $k \in \{1, \ldots, 5\}$, un bloque completo actúa como validación y los 4 restantes como entrenamiento.
- **Margen de purga ($\mathbf{P = 256}$):** Con ventanas deslizantes de $W = 256$ muestras (2.56 s), se aplica una separación de 256 muestras para garantizar **solapamiento cero (0.0)** entre entrenamiento y validación [8].

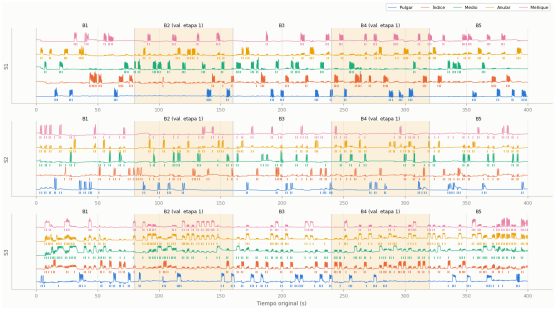


Figura 1. División de la señal en cinco bloques cronológicos (B1–B5) y zona de purga ($P = 256$ muestras) empleada en todos los experimentos de TT2. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: Esta división por bloques purgados garantiza que tanto las ablaciones arquitectónicas como la búsqueda en Optuna TPE evalúen la generalización real sobre intervalos futuros no observados [8, 21].

Evolución Arquitectónica en TT2: De A0 hasta A5b y A5

Cuatro modificaciones estructurales acopladas sobre la línea base de TT1 [9, 21]

Variante	Eje de Rediseño	Operador / Configuración	Efecto Técnico y Ganancia en CV (Época 50)
A0 **(Base TT1)**	Punto de partida	BatchNorm1d, Dropout 0.30	Línea base inicial de referencia ($\mathbf{0.5489}$).
A1	Normalización	LayerNorm por instante t	Elimina dependencia de estadísticas de lote ($+\mathbf{0.0605}$).
A2	Regularización	Dropout $0.30 \rightarrow \mathbf{0.10}$	Conserva detalles finos de la envolvente ($+\mathbf{0.0110}$ aislado).
A3	Sobremuestreo aislado	ConvTranspose1d sin A1/A2/A4	Inestable por sí sola; cae a 0.5173 ($-\mathbf{0.0316}$ vs. A0).
A4	Fusión en Decoder	Up $\rightarrow$ Concat(skip) $\rightarrow$ Conv	Filtra conjuntamente el mapa sobremuestreado y el *skip*.
A5b	Integración lineal	A1 + A2 + A4 + **Interp. Lineal**	Sobremuestreo fijo libre de pesos ($\mathbf{0.6779}$, $+0.1290$).
A5 **(Propuesta)**	Integración completa	A1 + A2 + A4 + ConvTranspose1d **DW**	Sobremuestreo aprendible por canal (groups$= C$, $-99.8\,\%$ params vs. densa; alcanza $\mathbf{0.6837}$, $+\mathbf{0.1349}$).

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Interpretación técnica: La convolución transpuesta *depthwise* (groups$= C$) en A5 añade solo $4C$ pesos por nivel (2048 vs. $1\,048\,576$ en el nivel $8f$), evitando la sobreparametrización y logrando la mayor fidelidad al acoplarse con LayerNorm y el nuevo orden del Decoder [21].

1. Función de Pérdida Híbrida Compuesta

Para evitar predicciones planas cercanas a la media, la función objetivo pondera en partes iguales el error de escala (MSE) y la distancia coseno temporal ($\mathcal{L}_{\cos}$) [19, 10]:

$$\mathcal{L}(\mathbf{Y}, \hat{\mathbf{Y}}) = 0.5 \ \mathrm{MSE}(\mathbf{Y}, \hat{\mathbf{Y}}) + 0.5\Big(1 - \mathrm{CosSim}_{\mathsf{temp}}(\mathbf{Y}, \hat{\mathbf{Y}})\Big)$$

- MSE: Penaliza desviaciones de amplitud absoluta en $[0, 1]$.
- $1 - \mathrm{CosSim}_{\mathsf{temp}}$: Maximiza directamente la correlación morfológica y la sincronía de fase de los picos de flexión.

2. Optimizador `Adam` con L_2 Acoplada

- **Regla de actualización:** `Adam` estándar con penalización L_2 acoplada en el gradiente ($\tilde{g}_i = \nabla_{w_i}\mathcal{L} + \lambda w_i$) [11].
- **Estabilidad numérica:** Tamaño de lote $B = 128$ y recorte de norma global de gradiente $\|\mathbf{g}\|_2 \leq 1.0$.

3. Política de *Early Stopping*

Selección del mejor *checkpoint* de validación bajo la regla:

$$\text{min_epochs} = 15, \quad \text{patience} = 10, \quad \text{max_epochs} = 50$$

Muestreador TPE en Optuna

- El estimador *Tree-structured Parzen Estimator* (TPE) modela dos densidades sobre el historial ($\gamma = 0.25$) [12, 13]:
  - $\ell(\boldsymbol{\lambda})$: Configuraciones en el cuartil superior.
  - $g(\boldsymbol{\lambda})$: Configuraciones restantes.
- Maximiza la mejora esperada seleccionando candidatos que maximizan el cociente $\ell(\boldsymbol{\lambda})/g(\boldsymbol{\lambda})$.
- **Función objetivo por sujeto s:**

$$J(\boldsymbol{\lambda}, s) = \frac{1}{5} \sum_{k=1}^{5} \left[\max_{e \in E_{s,k,\boldsymbol{\lambda}}} r_{s,k,e}^{\text{val}} \right]$$

Espacio de Búsqueda Mixto (Λ) y Presupuesto

Hiperparámetro	Escala	Dominio Explorado
`architecture_id`	Categórica	{`A5`, `A5b`}
Learning rate (η)	Log-continua	$[5 \times 10^{-5},\ 5 \times 10^{-4}]$
Regularización L_2 (λ)	Log-continua	$[10^{-7},\ 10^{-3}]$
Tamaño de kernel (k)	Categórica	$\{5,\ 7\}$
Niveles U-Net (L)	Entera	$\{4,\ 5\}$
Canales base (f)	Categórica	$\{64,\ 96\}$

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Presupuesto 100 % completado: 32 trials/sujeto (10 *warmups* balanceados 5 `A5`/5 `A5b` + 22 TPE) $\times 5$ folds $=$ **480** entrenamientos.

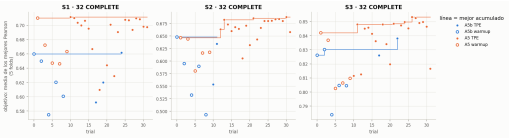


Figura 2. Historial de optimización a lo largo de los 32 ensayos por sujeto (96 trials totales) en Optuna TPE. **Fuente:** Obtenida del repositorio GitHub [21].

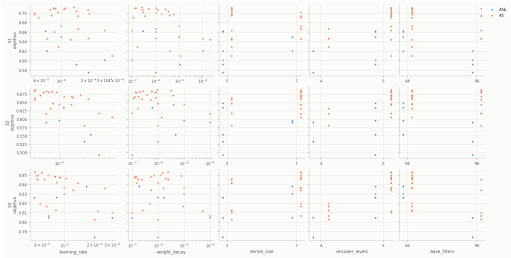


Figura 3. Relación entre complejidad paramétrica (N_{params}), familia arquitectónica (A5 vs. A5b) y correlación CV. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: En S1 y S3 las redes moderadas ($f = 64$, 9.35–12.71 M params) saturan tempranamente el techo de validación, mientras que en el paciente más complejo (S2) TPE identifica una mejora clara al escalar hacia mayor capacidad representacional ($k = 7, L = 5, f = 96$, 28.03 M params) [21].

Diseño Experimental y Mapa de las Cinco Etapas

Trazabilidad de los 723 entrenamientos bajo preprocesamiento fijo P0 [21]

Etapa Experimental (P0 fijo)	S1	S2	S3	Media	Aporte e Interpretación Metodológica
1. A0 Base (CV ép. 50)	0.4990	0.4289	0.7187	**0.5489**	Línea base inicial de referencia (15 fits).
2. A5 sin TPE (CV ép. 50)	0.6038	0.6216	0.8258	**0.6837**	$+\mathbf{0.1349}$ por rediseño arquitectónico ($14/15$ folds > 0).
2b. A5 sin TPE (*Checkpoint)**	0.7103	0.6466	0.8422	**0.7330**	$+\mathbf{0.0493}$ por parada temprana sobre históricos sin TPE.
3. A5 con TPE (Mejor trial CV)	0.7117	0.6878	0.8533	**0.7509**	$+\mathbf{0.0179}$ durante la búsqueda en Optuna (480 fits).
4. A5 Verificada (Semillas nuevas)	0.6929	0.6785	0.8402	**0.7372**	$+\mathbf{0.0041}$ neto global vs. 2b; $+\mathbf{0.0319}$ en S2 (60 fits).
5a. A5 Test Inicial (B1–B4)	0.6087	0.5226	0.7685	**0.6333**	Evaluación inicial en prueba con parada en B5 (9 fits).
5b. A5 Test Oficial (B1–B5)	**0.6723**	**0.5490**	**0.7796**	**0.6669**	$+\mathbf{0.0337}$ al reentrenar con los 5 bloques ($9/9 > 0$).

Fuente: Creación propia a partir del protocolo experimental implementado en GitHub [21].

Interpretación técnica: Todas las correlaciones se calculan sobre la trayectoria continua reconstruida con *overlap-add*, promediando los 5 dedos, los 5 bloques en CV y las **3 semillas completas en Test** (3042, 4042, 5042) sin elegir la mejor semilla [21].

Resultados Clave de Ablación

- **Mayor salto interno ($+0.1349$):** Pasar de `A0` (0.5489) a `A5` (0.6837) en época 50 mejora 14 **de los** 15 **pliegues** (`S2` gana $+0.1927$; única excepción `S1-B3` con -0.0359).
- **Lección de `A3` (0.5173):** Usar `ConvTranspose1d` de forma aislada degradó -0.0316. Su ventaja emerge solo al combinarse con `LayerNorm` (`A1`: $+0.0605$) y el nuevo orden del Decoder en `A5`.
- **Control experimental:** Se mantuvo fijo el preprocesamiento `P0` en las etapas posteriores para aislar sin confusión el aporte de `A5` y TPE.

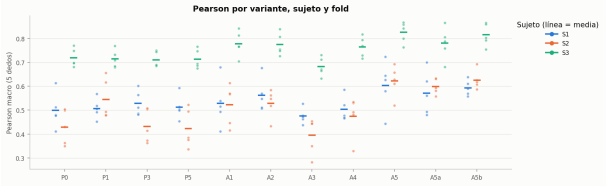


Figura 4. Correlación de Pearson macro por variante (`P0`–`P5` y `A1`–`A5b`), sujeto y pliegue en la época 50. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: El rediseño arquitectónico acoplado (`A0` → `A5`) constituye el factor individual de mayor impacto en todo el proyecto, superando ampliamente el efecto posterior del ajuste fino de hiperparámetros [21].

Puente Metodológico 2b

- **Sobreajuste al final de las 50 épocas:** Las curvas de validación alcanzan su máximo entre las épocas 18 y 35, degradándose ligeramente hacia la época 50.
- **Efecto puro del *checkpoint* ($+0.0493$):** Evaluar los mismos entrenamientos históricos de `A5` sin TPE con la regla de parada temprana ($\text{min} = 15, \text{patience} = 10$) eleva la media de 0.6837 a $\mathbf{0.7330}$.
- **Impacto por sujeto:** `S1` sube $+\mathbf{0.1066}$ ($0.6038 \rightarrow 0.7103$), `S2` $+0.0250$ y `S3` $+0.0164$.

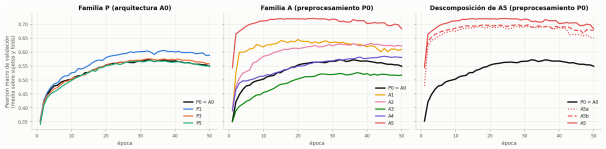


Figura 5. Evolución de la correlación de validación por época para las familias `P`, `A` y la descomposición hacia `A5`. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: Cuantificar este escalón de $+\mathbf{0.0493}$ evita un error metodológico común: atribuir falsamente a la optimización bayesiana una ganancia que en realidad proviene de seleccionar el mejor *checkpoint* temporal [14].

Auditoría Estadística de TPE

- **Etapa 3 (Mejor Trial TPE = 0.7509):** Frente a A5 con *checkpoint* (0.7330), la búsqueda aporta $+\mathbf{0.0179}$ en la media (S2 sube $+0.0413$).
- **Etapa 4 (Verificación con 2 semillas nuevas/fold = 60 fits):**
  - A5 **(0.7372) supera a** A5b **(0.7112)** por $+\mathbf{0.0260}$ con mejoras en los 3 sujetos.
  - Al descontar el sesgo del máximo [14], la ganancia global sobre 0.7330 es marginal ($+\mathbf{0.0041}$), pero **se mantiene un beneficio real en** S2 **($+\mathbf{0.0319}$)**.

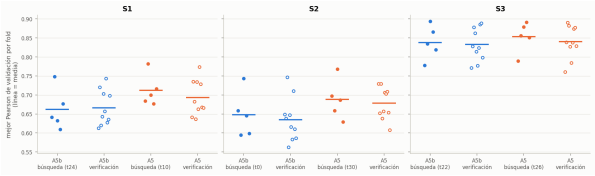


Figura 6. Contraste entre el puntaje de búsqueda TPE y la verificación con semillas independientes para A5 y A5b en los 3 sujetos. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: La verificación multi-semilla demostró que S1 y S3 ya operaban cerca de su techo con hiperparámetros base, mientras que TPE fue determinante para rescatar el desempeño del **Sujeto 2** ($+0.0319$) y confirmar la superioridad de A5 sobre A5b [21].

Configuraciones Seleccionadas por Sujeto y Regla de Épocas Fijas

Modelos ganadores de la familia `A5` y protocolo de transición al conjunto de prueba [21]

Sujeto	Trial	Kernel k	Niveles L	Canales f	Parámetros	Verif. CV	Horizonte Fijo Test (`B1–B5`)
S1	Trial 10	$k = 5$	$L = 5$	$f = 64$	**9.35** M	0.6929 ± 0.0566	**21** épocas ($\eta = 1.38 \times 10^{-4}$)
S2	Trial 30	$k = 7$	$L = 5$	$f = 96$	**28.03** M	0.6785 ± 0.0680	**32** épocas ($\eta = 5.16 \times 10^{-5}$)
S3	Trial 26	$k = 7$	$L = 5$	$f = 64$	**12.71** M	0.8402 ± 0.0369	**28** épocas ($\eta = 5.10 \times 10^{-5}$)
Media	—	—	—	—	16.70 M	**0.7372**	Mediana de 10 corridas de verif.

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Protocolo Inicial `b1b4_es_b5`

Entrena sobre los bloques `B1–B4` (80 % de los datos) y utiliza el bloque `B5` como validación interna para parada temprana. Desaprovecha el bloque más cercano al conjunto de prueba.

Protocolo Reentrenado `b1b5_fixed`

Integra el **100 % de los bloques de desarrollo (`B1–B5`)** entrenando durante la mediana exacta de épocas verificadas (21, 32 y 28), sin observar jamás el bloque de prueba oficial.

Etapa 5: Evaluación en el Conjunto de Prueba Oficial

Desempeño final auditado sobre las tres semillas independientes (3042, 4042, 5042) [15, 21]

Suj.	B1–B4	B1–B5 (Test)	CCC	MSE
S1	0.6087	$\mathbf{0.6723 \pm 0.0009}$	0.5534	0.6497
S2	0.5226	$\mathbf{0.5490 \pm 0.0143}$	0.4050	0.8667
S3	0.7685	$\mathbf{0.7796 \pm 0.0069}$	0.7694	0.3606
Media	**0.6333**	**0.6669** (+**0.0337**)	**0.5759**	**0.6257**

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Consistencia en las 9 Ejecuciones

- El protocolo b1b5_fixed supera a b1b4_es_b5 en las $9/9$ **parejas sujeto-semilla** ($+0.0635$ en S1, $+0.0264$ en S2, $+0.0111$ en S3).
- Mejora simultáneamente el CCC de Lin ($0.5210 \rightarrow \mathbf{0.5759}$) y reduce el MSE ($0.6597 \rightarrow \mathbf{0.6257}$) [15].

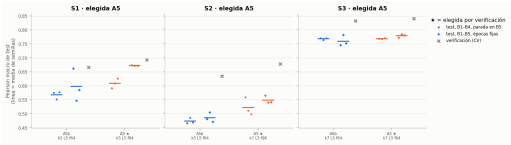


Figura 7. Puntajes en el conjunto de prueba oficial por sujeto y semilla: protocolo inicial (B1–B4) frente a reentrenamiento completo (B1–B5). **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: Por transparencia metodológica se reportan siempre ambas cifras: 0.6333 como primera evaluación en prueba y $\mathbf{0.6669}$ como resultado del protocolo reentrenado sobre los 5 bloques [21].

Dedo	S1	S2	S3	Media Test
1. Anular	0.7429	0.6431	0.7745	**0.7202**
2. Índice	0.7525	0.6197	0.7760	**0.7161**
3. Pulgar	0.6777	0.5835	0.8130	**0.6914**
4. Meñique	0.6085	0.4918	0.7982	**0.6328**
5. Medio	0.5798	0.4107	0.7322	**0.5742**
Media Sujeto	**0.6723**	**0.5490**	**0.7796**	**0.6669**

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Patrón Somatotópico y Biomecánico

- **Anular (0.7202) e Índice (0.7161)** presentan la mayor fidelidad de reconstrucción en los 3 sujetos.
- El **dedo Medio (0.5742)** constituye el mayor reto (S2 = 0.4107) por su fuerte coactivación tendinosa y solapamiento cortical con los dedos adyacentes.

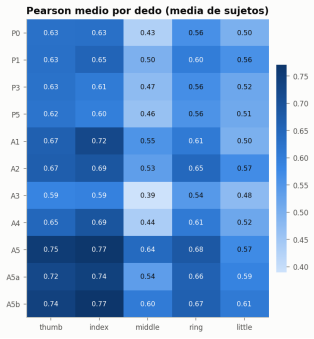


Figura 8. Mapa de calor de correlación de Pearson por dedo a través de las variantes evaluadas (media de los tres sujetos). **Fuente:** Obtenida del repositorio GitHub [21].

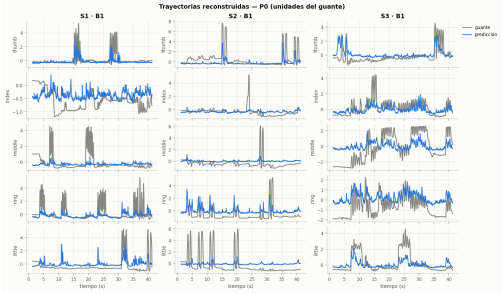


Figura 9. Modelo Base A0/P0 (0.5489 CV): predicciones con oscilaciones espurias. **Fuente:** Obtenida del repositorio GitHub [21].

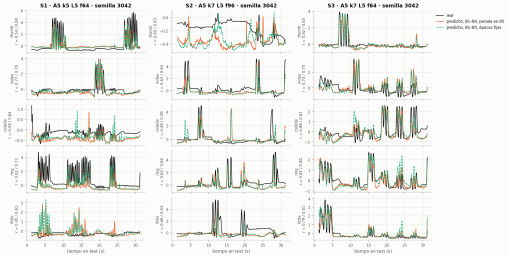


Figura 10. Modelo Final A5 en Test Oficial (0.6669): seguimiento preciso de flexión y reposo. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: Auditoría Automatizada (14/14 PASS): Las compuertas V01–V14 y el manifiesto SHA-256 (b26db4c4...) certifican cero solapamiento entre bloques, ajuste exclusivo de escaladores en entrenamiento y reproducibilidad determinista [21].

Comparación Crítica frente al Estado del Arte

Benchmark en el *Dataset 4* de la *BCI Competition IV* [16, 17, 18, 19, 21]

Método / Arquitectura Reportada en Literatura	Sujeto 1	Sujeto 2	Sujeto 3	Promedio
Switching linear model (Liang & Bougrain, 2012) [16]	0.48	0.24	0.56	0.43
Compact CNN (2018) / *Linear regression* (2017)	0.45	0.34	0.56	0.45–0.48
CNN-LSTM (Xie et al., 2018) [17] / *highGRM* (2022)	0.55–0.56	0.41–0.42	0.58–0.61	0.52–0.53
FingerFlex (U-Net 1D, Lomtev et al., 2022) [18]	0.64	0.56	0.73	**0.64**
DTCNet (Conv 3D dilatada, Wang et al., 2025) [19]	0.71	0.59	0.77	**0.69**
Nuestro Modelo Base `A0/P0` (CV ép. 50)	0.4990	0.4289	0.7187	0.5489
Nuestro Modelo `A5` (Test inicial `b1b4_es_b5`, 3 semillas)	0.6087	0.5226	0.7685	**0.6333**
Nuestro Modelo `A5` (Test reentrenado `b1b5_fixed`, 3 semillas)	**0.6723**	**0.5490**	**0.7796**	**0.6669**

Fuente: Creación propia a partir de [16, 18, 19] y resultados del repositorio GitHub [21].

Superación de *FingerFlex* [18]

`A5` (0.6669) supera a la referencia directa U-Net 1D (0.64) en `S1` **(**+0.0323**),** `S3` **(**+0.0496**) y en la media global (**+**0.0269)**.

Contraste frente a *DTCNet* [19]

`A5` (1D) supera a *DTCNet* (3D) en `S3` **(**0.7796 **vs.** 0.77**), en el dedo Anular (**0.7202 **vs.** 0.70**) y en** 8/15 **celdas sujeto-dedo**; la brecha radica en el dedo Medio (0.5742 vs. 0.67).

Conclusiones Generales y Hallazgos Esenciales (H1–H5)

Desacoplamiento estadístico del aporte de arquitectura, *checkpoint*, TPE y reentrenamiento [21]

Hallazgos sobre Arquitectura y HPO

- `H1` **(Rediseño Arquitectónico $+0.1349$):** El paso de `A0` (0.5489) a `A5` (0.6837) con `LayerNorm`, menor `Dropout`, *skip* previo y `ConvTranspose1d` *depthwise* fue el avance más determinante ($14/15$ folds positivos).
- `H2` **(Selección de *Checkpoint* $+0.0493$):** La parada temprana elevó `A5` sin TPE a $\mathbf{0.7330}$, separando el efecto temporal de la búsqueda de hiperparámetros.
- `H3` **(Beneficio Específico de TPE):** En verificación (0.7372), la mejora media fue marginal ($+0.0041$), pero resultó **sustancial en el Sujeto 2 ($+0.0319$)** y confirmó a `A5` sobre `A5b` ($+0.0260$).

Hallazgos en Prueba Oficial y Fisiología

- `H4` **(Reentrenamiento Completo 0.6669):** Integrar los 5 bloques (`B1`–`B5`) con la mediana de épocas verificadas superó al test inicial (0.6333) por $+\mathbf{0.0337}$ en las $9/9$ ejecuciones ($\mathrm{CCC} = 0.5759$).
- `H5` **(Variabilidad Inter-Sujeto e Inter-Dedo):** Se mantiene una brecha anatómica entre sujetos (S3 $= 0.7796$ vs. S2 $= 0.5490$) y entre dedos (Anular 0.7202 e Índice 0.7161 frente al acoplamiento biomecánico del Medio 0.5742).

Interpretación técnica: Conclusión central: Las decisiones estructurales sobre la topología de la red y la regla de selección temporal ejercen un impacto mayor que el ajuste fino de hiperparámetros, el cual actúa como un adaptador clave para sujetos con menor relación señal-ruido basal.

Evaluación del Cumplimiento de Objetivos

Tabla 1. Cumplimiento del objetivo general

Objetivo general	Estado de cumplimiento
Desarrollar un marco de configuración basado en redes neuronales profundas para la decodificación continua de movimientos de dedos a partir de señales electrocorticográficas del Dataset 4 de la BCI Competition IV, optimizando su arquitectura e hiperparámetros mediante optimización bayesiana y comparando su desempeño frente al modelo base y al estado del arte.	**Cumplido**

Tabla 2. Cumplimiento de los cuatro objetivos particulares

Objetivo	Objetivo particular	Estado de cumplimiento
Objetivo Particular 1	Implementar una metodología de filtrado, segmentación, normalización y extracción espectral libre de fuga de información temporal.	**Cumplido**
Objetivo Particular 2	Integrar el flujo continuo de modelado diseñando una arquitectura base y su evolución estructural para predecir trayectorias de flexión.	**Cumplido**
Objetivo Particular 3	Diseñar e implementar con Optuna un esquema de optimización bayesiana para buscar automáticamente arquitecturas e hiperparámetros por sujeto.	**Cumplido**
Objetivo Particular 4	Comparar el modelo optimizado frente al modelo base y al estado del arte bajo condiciones auditables.	**Cumplido**

Fuente: Creación propia a partir de los compromisos técnicos de la investigación [21].

Reto o Limitación	Implicación Metodológica	Medida de Rigor Implementada
1. Muestra clínica ($N = 3$)	Alta variabilidad inter-sujeto (S2 $= 0.5490$ a S3 $= 0.7796$) que impide inferencias poblacionales.	Reporte desglosado por paciente y dedo, aplicando búsqueda TPE personalizada por sujeto.
2. Optimismo en 32 trials TPE	Seleccionar el máximo de 32 ensayos introduce sesgo de selección (0.7509) [14].	Ejecución de 60 entrenamientos de verificación con semillas nuevas (0.7372) y separación del *checkpoint* (0.7330).
3. Carácter de `b1b5_fixed`	El reentrenamiento con los 5 bloques se diseñó tras observar el primer test (0.6333).	Reporte conjunto de ambos protocolos (0.6333 inicial y 0.6669 reentrenado) con épocas fijadas por mediana de CV.
4. Acoplamiento del dedo Medio	Menor correlación en prueba (0.5742) frente a Anular (0.7202) e Índice (0.7161).	Evaluación individualizada por dedo en las 15 celdas sujeto-dedo frente al estado del arte.

Fuente: Creación propia [14, 21].

Trabajo a Futuro: Optimización para Sistemas Embebidos

Estrategias de compresión de modelos para reducir recursos computacionales [20, 21]

1. Destilación de Conocimiento

- **Transferencia maestro-estudiante (*Knowledge Distillation*):** Transferir el conocimiento de los modelos `A5` (9.35 M a 28.03 M de parámetros) a arquitecturas más compactas [20].
- **Alineación de representaciones:** Entrenar la red ligera para reproducir tanto las trayectorias continuas de los cinco dedos como las activaciones latentes del decodificador.
- **Beneficio operativo:** Disminuir el costo de inferencia manteniendo la precisión alcanzada en la prueba oficial ($r = 0.6669$).

2. Poda Estructurada de Parámetros y Canales

- **Eliminación de filtros redundantes:** Reducir el tamaño de las redes `A5` podando el $50\,\%$ de los canales en las etapas profundas $4f$ y $8f$ (que concentran $> 72\,\%$ de los pesos).
- **Criterio de relevancia por canal:** Seleccionar filtros mediante la norma ℓ_1 de los kernels y el factor de escala γ_o de `LayerNorm`:

$$\mathcal{I}_{\text{LN}}(o) = |\gamma_o| \cdot \|\mathbf{W}_{o,:,:}\|_2$$

- **Despliegue en sistemas embebidos:** Reducción proyectada del **75 % en FLOPs y memoria** (< 3 M de parámetros) para neuroprótesis de bajo consumo.

Interpretación técnica: Ambas líneas permiten trasladar el desempeño de las redes `A5` hacia hardware embebido con restricciones estrictas de memoria, cómputo y disipación térmica [20, 21].

Referencias Bibliográficas I

Fuentes científicas, metodológicas y de estado del arte citadas en la presentación

[1] K. J. Miller and G. Schalk, "Prediction of finger flexion: 4th Brain-Computer Interface data competition (Dataset 4)," *BCI Competition IV*, 2008. [Online]. Available: `https://www.bbci.de/competition/iv/desc_4.pdf`

[2] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, "BCI2000: A general-purpose brain-computer interface (BCI) system," *IEEE Transactions on Biomedical Engineering*, vol. 51, no. 6, pp. 1034–1043, 2004.

[3] G. Schalk and E. C. Leuthardt, "Brain-computer interfaces using electrocorticographic signals," *IEEE Reviews in Biomedical Engineering*, vol. 4, pp. 140–154, 2011.

[4] K. Volkova, M. A. Lebedev, A. Kaplan, and A. Ossadtchi, "Decoding movement from electrocorticographic activity: A review," *Frontiers in Neuroinformatics*, vol. 13, p. 74, 2019.

[5] D. T. Bundy, M. Pahwa, N. Szrama, and E. C. Leuthardt, "Decoding three-dimensional reaching movements using electrocorticographic signals in humans," *Journal of Neural Engineering*, vol. 13, no. 2, p. 026021, 2016.

[6] J. Gruenwald, S. Sieghartsleitner, C. Kapeller, J. Scharinger, K. Kamada, P. Brunner, and C. Guger, "Characterization of high-gamma activity in electrocorticographic signals," *Frontiers in Neuroscience*, vol. 17, p. 1206120, 2023.

[7] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proc. 4th Int. Conf. Practical Applications of Knowledge Discovery and Data Mining*, vol. 1, 2000, pp. 29–39.

Referencias Bibliográficas II

Fuentes científicas, metodológicas y de estado del arte citadas en la presentación

[8] D. R. Roberts *et al.*, "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017.

[9] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, vol. 9351, Springer, 2015, pp. 234–241.

[10] M. Sliwowski, "Artificial intelligence for real-time decoding of motor commands from ECoG of disabled subjects for chronic brain computer interfacing," Ph.D. dissertation, Université Grenoble Alpes, 2022.

[11] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019, pp. 1–19.

[12] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, "Algorithms for hyper-parameter optimization," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 24, 2011, pp. 2546–2554.

[13] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631.

[14] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[15] L. I.-K. Lin, "A concordance correlation coefficient to evaluate reproducibility," *Biometrics*, vol. 45, no. 1, pp. 255–268, 1989.

[16] N. Liang and L. Bougrain, "Decoding finger flexion from electrocorticographic signals using a sparse Gaussian process," *Frontiers in Neuroscience*, vol. 6, p. 91, 2012.

[17] Z. Xie, O. Schwartz, and A. Prasad, "Decoding of finger trajectory from ECoG using deep learning," *Journal of Neural Engineering*, vol. 15, no. 3, p. 036009, 2018.

[18] V. Lomtev, A. Kovalev, and A. Timchenko, "FingerFlex: Inferring finger trajectories from ECoG signals," *arXiv preprint arXiv:2211.01960*, 2022.

[19] F. Wang, Z. Luo, W. Lv, and X. Zhu, "DTCNet: Finger flexion decoding with three-dimensional ECoG data," *Frontiers in Computational Neuroscience*, vol. 19, p. 1627819, 2025.

[20] Y. Xie *et al.*, "BrainDistill: Implantable motor decoding with task-specific knowledge distillation," *arXiv preprint arXiv:2601.17625*, 2026.

[21] S. Rodas Bautista and J. Valencia San Roman, "TPE_ECoG: Optimización mediante TPE para la decodificación de señales ECoG," GitHub, 2026. [Online]. Available: `https://github.com/SaulRodas/TPE_ECoG`

Ciclo CRISP-DM Adaptado

1. **Problema:** Regresión continua (r, CCC, MSE).
2. **Datos:** Auditoría de electrodos y ZOH (25 Hz).
3. **Preparación (P0):** CWT Morlet, Spline y purga $P = 256$.
4. **Modelado:** U-Net 1D (A0 $\rightarrow$ A5) + Optuna **TPE**.
5. **Evaluación:** Reconstrucción *overlap-add* en 5 etapas.
6. **Trazabilidad:** Manifiesto SHA-256 y V01–V14.

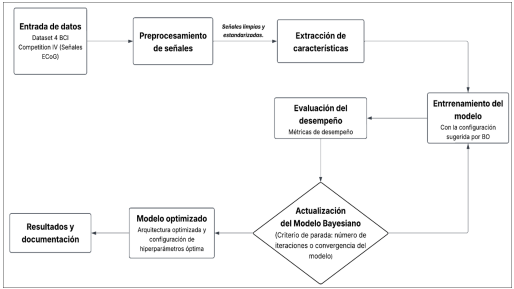


Figura A.1. Flujo general del marco desarrollado desde la ingesta ECoG (1000 Hz) hasta la reconstrucción continua de los 5 dedos (100 Hz). **Fuente:** Creación propia a partir de [7] y el repositorio GitHub [21].

Interpretación técnica: El marco metodológico desacopla el preprocesamiento fijo (P0), el rediseño arquitectónico (A0$\rightarrow$A5) y la optimización bayesiana (**TPE**), permitiendo auditar el aporte de cada fase.

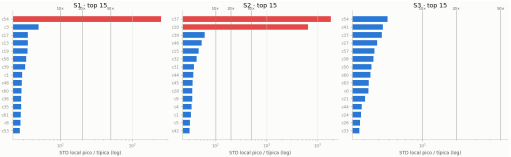


Figura A.2. Ranking de anomalías de amplitud y varianza por electrodo en los tres sujetos (S1, S2 y S3). **Fuente:** Obtenida del repositorio GitHub [21].

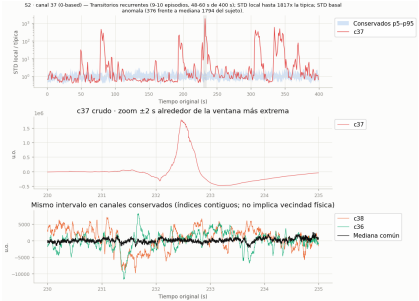


Figura A.3. Corrupción instrumental severa en el canal c037 del Sujeto 2 ($1817\times$ la desviación estándar basal). **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: Exclusión fija previa: S1 excluye c54 ($62 \rightarrow 61$), S2 excluye c20 y c37 ($48 \rightarrow 46$), y S3 excluye c49 ($64 \rightarrow 63$). Esto evita que un promedio común inyecte pulsos de $> 1800\sigma$ en los canales sanos antes de aplicar Referencia Mediana Común (CMR) [21].

Biomarcadores Corticales en ECoG

- **Bandas μ/β (8–30 Hz):** Exhiben desincronización (ERD) difusa y no específica al inicio del movimiento.
- **Banda High-Gamma (40–200 Hz):** Refleja el disparo poblacional neuronal local en la capa V de la corteza motora primaria (M1) [5, 6].
- **Selectividad somatotópica:** La potencia High-Gamma se correlaciona de forma directa y focalizada con la cinemática individual de cada dedo [4].

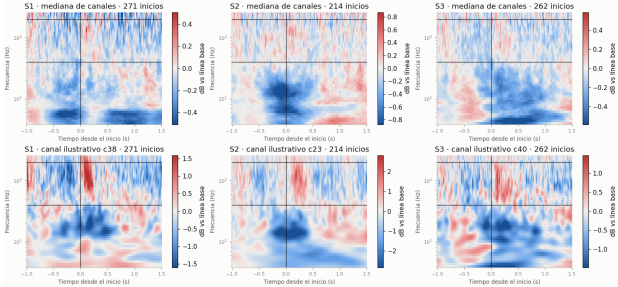
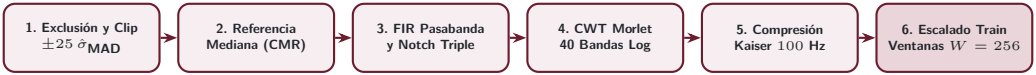


Figura A.4. Perturbación espectral ligada a eventos (ERSP) durante episodios de movimiento frente a reposo en la banda High-Gamma (40–200 Hz). **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: La concentración de energía motora en la banda 40–200 Hz sustenta el uso de un banco denso de **40 ondículas complejas de Morlet** para extraer la envolvente instantánea de potencia en cada electrodo [4, 21].

Anexo A4: Pipeline P0 y Compresión Temporal de Datos

Acondicionamiento tiempo-frecuencia y reducción de 1000 Hz a 100 Hz [4, 21]



Etapas 1 a 3: Limpieza y Filtrado Espectral

- **Exclusión fija + Clip MAD:** Canales válidos $(\text{S1}: 61, \text{S2}: 46, \text{S3}: 63)$ y acotamiento $\pm 25\,\hat{\sigma}_{\text{MAD}}$.
- **Referencia Mediana Común (CMR):** Sustracción de la mediana espacial instantánea, inmune a valores atípicos residuales.
- **Filtros FIR de fase cero:** Pasabanda en **40–200** Hz (331 taps) y Notch en **60, 120, 180** Hz (1651 taps).

Etapas 4 a 6: Escalograma y Compresión de Datos

- **40 Wavelets de Morlet ($n_c = 7$):** Potencia instantánea $P_{c,f_i}(t) = |(x_c * \psi_{f_i})(t)|^2$ en escala logarítmica.
- **Compresión temporal ($10\times$) a 100 Hz:** Decimación con filtro FIR Kaiser antialias (243 taps) y recorte de $\pm\mathbf{125}$ muestras de borde (1250 ms).
- **Escalado sin fuga:** `RobustScaler`$(10, 90)$ en ECoG y `MinMaxScaler`$[0, 1]$ en guante, ajustados **solo en train**.

Anexo A5: Reconstrucción del Guante y Adelanto Temporal ($\tau = 20$ ms)

Interpolación por Spline Cúbico y compensación del desfase cortico-muscular [1, 21]

Acondicionamiento de Etiquetas $y_d(t)$

- **Problema del ZOH crudo:** El guante actualiza su lectura cada 40 ms (25 Hz), generando escalones artificiales con derivadas nulas y saltos discontinuos.
- **Interpolación Spline Cúbico (*Not-a-Knot*):** Se extraen los nodos reales ($n = 40m$) y se reconstruye una curva suave con continuidad C^2 a **100** Hz.
- **Adelanto temporal ($\tau = 20$ ms):** Desplazamiento de $+2$ muestras a 100 Hz para compensar la latencia fisiológica entre la corteza motora y la flexión mecánica del dedo.

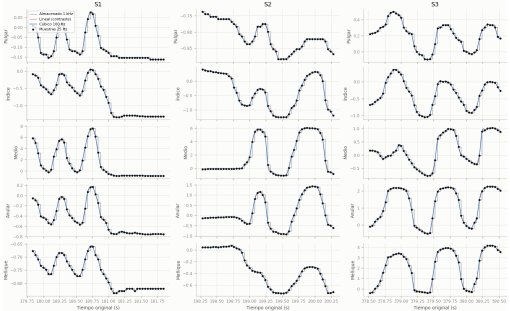
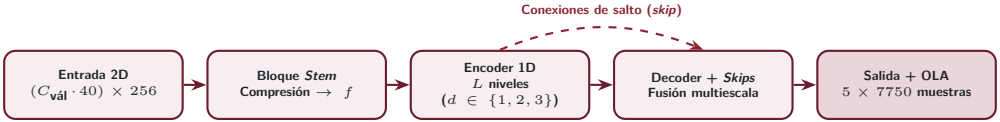


Figura A.5. Comparación entre la señal escalonada original del guante (ZOH a 25 Hz) y la trayectoria continua reconstruida mediante Spline Cúbico a 100 Hz. **Fuente:** Obtenida del repositorio GitHub [21].

Interpretación técnica: La interpolación por Spline Cúbico elimina los artefactos de escalón del dataglove y permite entrenar la red neuronal con objetivos cinemáticos físicamente diferenciables [21].

Anexo A6: Diseño de la Arquitectura Base A0 y Compresión Espectral

Topología U-Net 1D (EncoderDecoder1D) desarrollada en TT1 [9, 18, 21]



Compresión Espectral y Codificador

- **Compresión espacial-espectral (*Stem*):** Reduce la dimensión de entrada ($2440, 1840$ o 2520 canales tiempo-frecuencia) hacia $f \in \{64, 96\}$ mapas latentes.
- **Codificador con dilatación:** $L \in \{4, 5\}$ niveles con multiplicadores $[1, 2, 4, 8, 8] \cdot f$, activación GELU y dilatación $d \in \{1, 2, 3\}$ para ampliar el campo receptivo temporal.

Decodificación y Reconstrucción Continua

- **Conexiones de salto (*Skip Connections*):** Preservan la localización temporal fina de las envolventes High-Gamma [9].
- **Reconstrucción *Overlap-Add* (OLA):** Las predicciones sobre 119 ventanas deslizantes ($W = 256$, paso 64) se promedian para reconstruir los $N = 7750$ instantes completos de cada bloque.

Índice de Anexos Adicionales para Preguntas del Jurado

Respaldo técnico exhaustivo organizado por eje temático de defensa [21]

1. Preprocesamiento y Filtrado Espectral

- Anexo A7 Exclusión fija de canales sin etiquetas (`c54, c20, c37, c49`).
- Anexo A8 Ecuación CMR vs. CAR y filtro FIR Notch (1651 taps).
- Anexo A9 Justificación High-Gamma y decimación Antialias Kaiser.
- Anexo A10 Ablaciones secundarias de preprocesamiento (`P0, P1, P3, P5`).

2. Etiquetas, Auditoría Antifuga y Ablaciones

- Anexo A11 Desescalonado ZOH (25 Hz), purga $P = 256$ y *Overlap-Add*.
- Anexo A12 Huella SHA-256 y las 14 compuertas `V01-V14` (`pytest`).
- Anexo A13 Desglose `A0`–`A5`/`A5b` y deltas apareados ($14/15$ folds).

3. Parámetros, Checkpoint, TPE y Test Oficial

- Anexo A14 Matemática `A5b` vs. `A5` y conteo de parámetros (9.35–28.03 M).
- Anexo A15 Simulación retrospectiva de checkpoint ($0.6837 \rightarrow 0.7330$).
- Anexo A16 Matemática TPE (ℓ/g), descomposición de $+0.0672$ y 60 folds.
- Anexo A17 Protocolos de Test (0.6333 vs. 0.6669) y brecha CV vs. Test.

4. Estado del Arte, Trazabilidad CSV y Poda

- Anexo A18 Comparación celda a celda (15 pares) `A5` vs. *DTCNet* (2025).
- Anexo A19 Matriz completa de 16 archivos CSV y 6 reglas de cálculo.
- Anexo A20 Gobernanza de datos clínicos y formulación de Poda Estructurada.

Anexo A7: Auditoría de Calidad y Exclusión Fija de Canales Defectuosos

Pregunta del jurado: ¿Por qué se excluyeron electrodos específicos y cómo garantizan que no usaron las etiquetas para elegirlos?



Figura A.6. Anomalía en S1–c054 ($62 \rightarrow 61$). **Fuente:** Obtenida de GitHub [21].

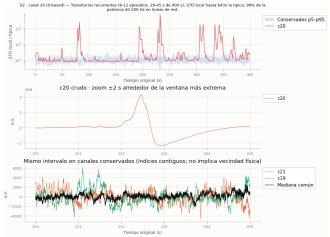


Figura A.7. Artefactos en S2–c020 ($48 \rightarrow 46$). **Fuente:** Obtenida de GitHub [21].

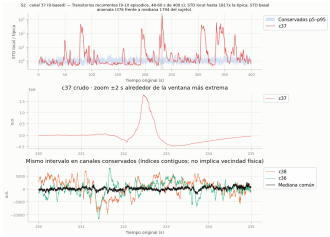


Figura A.8. Transitorio en S2–c037 ($> 1800\sigma$). **Fuente:** Obtenida de GitHub [21].

Inspección Ciega a Etiquetas y Extirpación Previa a la Referencia Espacial

- **Auditoría exclusivamente sobre ECoG crudo de desarrollo:** La detección de saturación y varianza anómala se ejecutó sin consultar las trayectorias del guante (`dataglove`), bloqueando cualquier sesgo de selección de características [21].
- **Canales extirpados antes de la CMR:** S1: canal 54 ($62 \rightarrow 61$); S2: canales 20 y 37 ($48 \rightarrow 46$); S3: canal 49 ($64 \rightarrow 63$).

Volver al Índice Extra

Anexo A8: Referencia Común a la Mediana (CMR) vs. CAR y Filtrado FIR Notch

Pregunta del jurado: ¿Por qué usar CMR en lugar del promedio común (CAR) y cómo se eliminó el ruido de línea de 60 Hz?

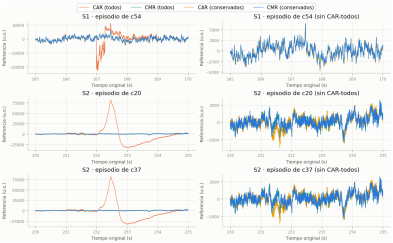


Figura A.9. Inmunidad de CMR frente a contaminación global en CAR. **Fuente:** Obtenida de GitHub [21].

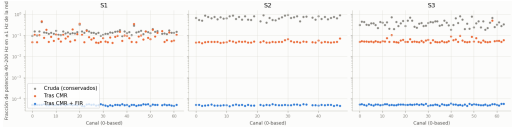


Figura A.10. Supresión eléctrica en $60, 120, 180$ Hz con Notch triple. **Fuente:** Obtenida de GitHub [21].

Fundamento Matemático de Robustez Espacial y Espectral

- **Referencia Común a la Mediana (CMR):** $\widetilde{X}_{c,t} = X_{c,t} - \text{mediana}_{j \in C_{\text{válidos}}}(X_{j,t})$. La mediana posee un **punto de ruptura del** $50\,\%$ e impide que un artefacto local residual contamine a los canales sanos, a diferencia del promedio CAR [3, 21].
- **Filtro FIR Notch de fase cero (**1651 **taps):** Atenúa > 40 dB en $\mathbf{60, 120}$ y $\mathbf{180}$ Hz sin distorsión de fase.

Volver al Índice Extra

Anexo A9: Justificación High-Gamma (40–200 Hz) y Decimación Antialias Kaiser

Pregunta del jurado: ¿Por qué acotar las wavelets de Morlet a 40–200 Hz y cómo evitaron el aliasing al bajar de 1000 Hz a 100 Hz?

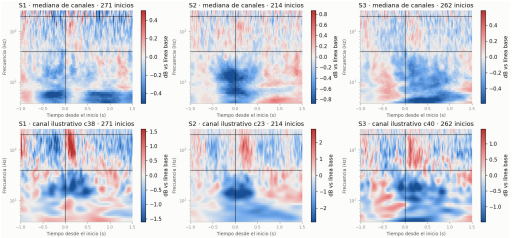


Figura A.11. Actividad motora acoplada en banda High-Gamma (40–200 Hz). **Fuente:** Obtenida de GitHub [21].

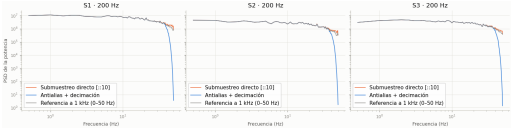


Figura A.12. Decimación FIR Kaiser (243 taps, −60 dB). **Fuente:** Obtenida de GitHub [21].

Acoplamiento Tiempo-Frecuencia y Prevención del Plegado Espectral (*Aliasing*)

- **Banco CWT de Morlet (40 escalas logarítmicas, $n_c = 7$ ciclos):** Captura la envolvente de potencia sináptica local en 40–200 Hz [4, 5].
- **Decimación Antialias (1000 Hz → 100 Hz, Nyquist = 50 Hz):** El filtro FIR con ventana de Kaiser (243 taps, rechazo de −60 dB) elimina fluctuaciones rápidas antes de diezmar por factor 10, evitando el plegado espectral sobre la envolvente [21].

Volver al Índice Extra

Anexo A10: Ablaciones Secundarias de Preprocesamiento (P0, P1, P3, P5)

Pregunta del jurado: ¿Qué ocurrió cuando probaron variantes del preprocesamiento sobre la red base A0?

Variante	Descripción del cambio en el pipeline (sobre red base A0, época 50)	S1	S2	S3	Media CV (r)	Δr vs. P0
P0 **(Fijado)**	Pipeline de referencia fijado (Exclusión + CMR + FIR + 40 Morlet + Kaiser)	0.4990	0.4289	0.7187	0.5489	—
P1	Sin referencia espacial CMR (conservando el resto de P0 idéntico)	0.4992	**0.5446**	0.7220	**0.5886**	**+0.0397**
P3	Variante espectral secundaria evaluada en Sección 3.6	—	—	—	0.5572	+0.0084
P5	Variante de acondicionamiento secundaria evaluada en Sección 3.6	—	—	—	0.5498	+0.0009

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Lectura Metodológica Rigurosa (Sección 3.6 del Reporte Experimental)

- **Origen de la diferencia en P1:** Al evaluar P1 (sin CMR) sobre la arquitectura inicial A0 en la época 50, la media subió a **0.5886** ($\Delta = +0.0397$), concentrada casi por completo en el **Sujeto 2 (+0.1157)**.
- **Por qué P0 se mantuvo fijo:** La búsqueda bayesiana **TPE** y las ablaciones A1–A5 se ejecutaron con P0 congelado para garantizar comparabilidad estricta; P1 no fue evaluado de forma controlada con la arquitectura final A5 optimizada.
- **Interpretación honesta:** Por ello, P0 se documenta como el **pipeline de referencia fijado para la comparabilidad experimental**, y no como el mejor preprocesamiento posible demostrado [21].

Volver al Índice Extra

Anexo A11: Desescalonado ZOH (25 Hz), Purga ($P = 256$) y *Overlap-Add*

Pregunta del jurado: ¿Cómo se corrigió el escalonado del guante y cómo se reconstruye la trayectoria continua para medir Pearson?

1. Desescalonado ZOH y Purga Antifuga

- **Almacenamiento ZOH:** El guante muestrea a 25 Hz pero se repite cada 40 muestras a 1000 Hz: $\texttt{train_dg}[n] = g_{\text{real}}[\lfloor n/40 \rfloor]$.
- **Spline + Adelanto:** Se extraen las muestras reales ($n = 40m$), se interpola con Spline Cúbico *Not-a-Knot* a 100 Hz y se adelanta $\tau = 20$ ms ($+2$ muestras).
- **Bordes y Purga:** Recorte de ± 125 muestras por bloque ($N = 7750$ válidas) y purga de $\mathbf{P = 256}$ muestras en fronteras de train adyacentes a validación.

2. Reconstrucción *Overlap-Add* (119 Ventanas)

Se deslizan 118 ventanas ($W = 256, s = 64$) más la ventana #119 anclada en $[7494, 7750)$, promediando $\widehat{Y}_d[k] = S_d[k]/C[k]$ antes de medir Pearson sobre la trayectoria completa.

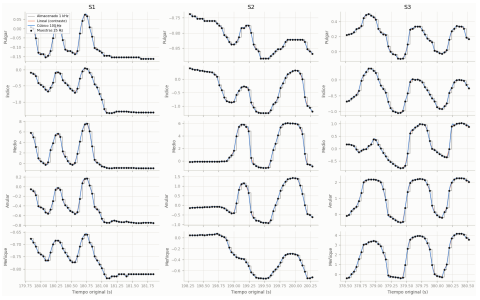


Figura A.13. Eliminación de escalones ZOH (25 Hz) mediante Spline Cúbico a 100 Hz. **Fuente:** Obtenida del repositorio GitHub [21].

Volver al Índice Extra

Anexo A12: Huella Criptográfica SHA-256 y las 14 Compuertas (V01–V14)

Pregunta del jurado: ¿Qué pruebas de software certifican que no existió fuga de datos (*data leakage*) entre bloques?

Bloque	Compuertas pytest	Verificación automatizada y garantía metodológica certificada
V01–V03	Integridad de origen y canales	Inmutabilidad de archivos .mat crudos, bloqueo estricto de test_labels durante desarrollo y exclusión fija de canales corruptos previa al cálculo de la mediana espacial CMR.
V04–V06	Partición, escalado y latencia	Separación cronológica con purga $P = 256$, ajuste de RobustScaler$(10, 90)$ y MinMaxScaler$[0, 1]$ exclusivamente sobre train, y alineación temporal $\tau = 20$ ms.
V07–V08	**Experimento contrafactual bit a bit**	Se inyecta un impulso gigante ($\mathbf{10^6} \times \max$ |ECoG|) en el bloque de validación crudo; al regenerar el fold, los tensores válidos de entrenamiento permanecen **idénticos bit a bit (tolerancia** $= 0.0$**)**.
V09–V14	Soporte DSP, OLA y métricas	Verificación de bordes FIR/Morlet (± 125 muestras), conteo exacto de 119 ventanas, cobertura $C[k] \geq 1$ en *overlap-add*, validez de A0–A5 y fórmulas de r, CCC y MSE.

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Identificador Inmutable pipeline_id (SHA-256)

Cada artefacto preprocesado registra un hash criptográfico **SHA-256** derivado de los hiperparámetros de filtrado, escalado y partición, impidiendo mezclar tensores de distintas configuraciones [21].

Volver al Índice Extra

Anexo A13: Desglose de Ablaciones Arquitectónicas (A0–A5, A5b) y Deltas

Pregunta del jurado: ¿Por qué no se puede afirmar que ConvTranspose1d mejora el rendimiento por sí sola?

Red	Configuración (época 50 fija)	Media CV	Δr vs. A0
A0/P0	Base U-Net 1D (BatchNorm1d)	0.5489	—
A1	+ LayerNorm por grupo temporal	0.6094	+0.0605
A2	+ Dropout espacial $p = 0.10$	0.6219	+0.0731
A3	+ ConvTranspose1d aislada	**0.5173**	**−0.0316**
A4	+ *Skip* previo a Conv1d	0.5806	+0.0317
A5b	Combinada (A1+A2+A4) con interp.	0.6779	+0.1291
A5	Combinada + ConvTranspose *depthwise*	**0.6837**	**+0.1349**

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Deltas Apareados A0 → A5 (14/15 Folds +)

S1: $+0.1048$ ($4/5$ folds; única excepción S1–B3 con -0.0359).
S2: $+\mathbf{0.1927}$ ($5/5$ folds) | S3: $+\mathbf{0.1070}$ ($5/5$ folds).

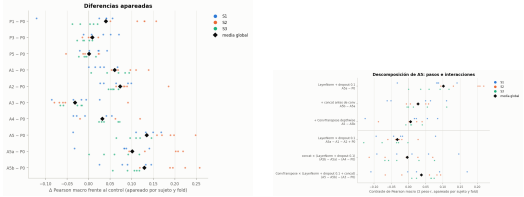


Figura A.14. Izquierda: deltas apareados por pliegue (A0 → A5). Derecha: contrastes de efectos individuales y sinérgicos. **Fuente:** Obtenida del repositorio GitHub [21].

Volver al Índice Extra

Anexo A14: Matemática A5b vs. A5 y Conteo de Parámetros por Sujeto

Pregunta del jurado: ¿Cuál es la diferencia matemática entre el decoder de A5b y A5, y cuántos parámetros tiene cada red?

1. Interpolación (A5b) vs. ConvTranspose1d (A5)

- **Variante A5b (0 parámetros en sobremuestreo):** Emplea interpolación lineal vectorizada con pesos geométricos fijos (0.75 y 0.25) para duplicar la resolución temporal en cada nivel del decodificador.
- **Variante A5 (ConvTranspose1d *depthwise*):** Configura $k = 4, s = 2, p = 1, \text{groups} = C$, añadiendo solo $\mathbf{4C}$ pesos por nivel. Incluye a la interpolación lineal como caso particular exacto y aprende el perfil de reconstrucción temporal por canal [21].

2. Conteo de Parámetros Ganadores (tpe_trials.csv)

Sujeto	Trial	Topología (k, L, f)	Canales ECoG	Parámetros
S1	$\#10$	$k = 5, L = 5, f = 64$	61×40	**9.35** M
S2	$\#30$	$k = 7, L = 5, f = 96$	46×40	**28.03** M
S3	$\#26$	$k = 7, L = 5, f = 64$	63×40	**12.71** M

Fuente: Creación propia, obtenida del repositorio GitHub [21].

El mayor tamaño en S2 (28.03 M) responde al incremento conjunto del ancho base ($f = 96$) y del kernel ($k = 7$) elegido por TPE.

Volver al Índice Extra

Anexo A15: Simulación Retrospectiva de Checkpoint antes de TPE (Etapa 2b)

Pregunta del jurado: ¿Por qué es indispensable reportar 0.7330 por separado antes de evaluar el aporte de TPE?

Sujeto	A5 Época 50	A5 Checkpoint (2b)	Ganancia Δr
S1	0.6038	**0.7103**	**+0.1066**
S2	0.6216	0.6466	+0.0250
S3	0.8258	0.8422	+0.0164
Media	0.6837	**0.7330**	**+0.0493**

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Separación Rigurosa de Efectos (ablation_retrospective.csv)

Al aplicar retrospectivamente la regla de *Early Stopping* (min $= 15$, paciencia $= 10$, max $= 50$) sobre `history_A5.csv`, la media sube $+0.0493$. Este incremento se debe al criterio de selección de época y **no debe acreditarse a TPE**.

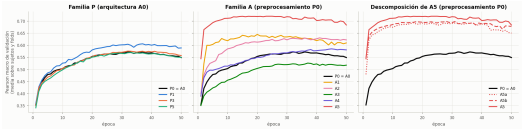


Figura A.15. Curvas de validación de A5 donde el óptimo en S1 se alcanza antes de la época 50. **Fuente:** Obtenida del repositorio GitHub [21].

Volver al Índice Extra

Anexo A16: Matemática TPE ($\ell(\lambda)/g(\lambda)$), Descomposición de $+0.0672$ y 60 Folds

Pregunta del jurado: ¿Cuánto mejoró realmente TPE durante la búsqueda y cuánto beneficio persistió al cambiar las semillas?

Transición / Etapa en CV	S1	S2	S3	Media CV
1. A5 época 50 fija	0.6038	0.6216	0.8258	0.6837
2. A5 con checkpoint ($\Delta = +0.0493$)	0.7103	0.6466	0.8422	0.7330
3. Mejor trial TPE ($\Delta = +0.0179$)	0.7117	0.6879	0.8532	0.7509
4. A5 TPE verificado ($\Delta = +0.0041$)	0.6928	**0.6785**	0.8402	**0.7372**
A5b TPE verificado (60 runs)	0.6682	0.6540	0.8114	0.7112

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Diagnóstico Estadístico del Aporte de TPE

- **Búsqueda ($+0.0179$):** Sujeta al optimismo de elegir el máximo de 32 trials.
- **Verificación (2 semillas nuevas $\times$ 5 folds):** Ganancia global de $+0.0041$, pero mejora sólida y real en **S2 ($+\mathbf{0.0319}$)**. Además, A5 supera a A5b por $+\mathbf{0.0260}$ en los 3 sujetos.

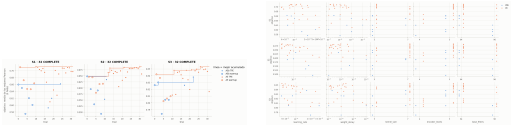


Figura A.16. Historial de los 96 trials TPE y relación parámetros vs. objetivo. **Fuente:** Obtenida del repositorio GitHub [21].

Volver al Índice Extra

Anexo A17: Protocolos de Test (0.6333 vs. 0.6669) y Brecha CV vs. Test

Pregunta del jurado: ¿Por qué existe un primer test de 0.6333 y un segundo de 0.6669, y por qué difieren del 0.7372 de CV?

Protocolo de Test	Esquema de entrenamiento final (3 semillas/sujeto)	S1	S2	S3	Media r	CCC	MSE
`b1b4_es_b5` **(Inicial)**	Entrena en `B1`–`B4` + *Early Stopping* monitoreando `B5`	0.6087	0.5226	0.7685	0.6333	0.5412	0.6962
`b1b5_fixed` **(Posterior)**	Entrena en `B1`–`B5` ($100\,\%$) + épocas fijas $(21, 32, 28)$	$\mathbf{0.6723}$	$\mathbf{0.5490}$	$\mathbf{0.7796}$	$\mathbf{0.6669}$	$\mathbf{0.5759}$	$\mathbf{0.6257}$
Diferencia (Δ)	Mejora consistente en $\mathbf{9/9}$ pares sujeto-semilla	$+0.0635$	$+0.0264$	$+0.0111$	$+\mathbf{0.0337}$	$+0.0347$	-0.0705

Fuente: Creación propia, obtenida del repositorio GitHub [21].

Interpretación Prudente y Explicación de la Diferencia entre CV (0.7372) y Test (0.6669)

- **Por qué se reportan ambos protocolos (`tpe_test_protocols.csv`):** El salto de $+0.0337$ refleja el cambio de protocolo completo (incorporar `B5` al entrenamiento y fijar épocas de CV); como `b1b5_fixed` se formuló tras observar 0.6333, se reporta transparentemente como resultado final exploratorio.
- **Por qué 0.7372 (CV) vs. 0.6669 (Test) no es una "caída de entrenamiento":** Son mediciones sobre particiones distintas: la CV promedia 5 bloques internos de desarrollo (320 s), mientras que el Test evalúa un segmento temporal futuro e independiente (200 s) sujeto a deriva no estacionaria de la señal ECoG [21].

Volver al Índice Extra

Anexo A18: Comparación Celda a Celda por Dedo y Sujeto: A5 vs. *DTCNet* (2025)

Pregunta del jurado: ¿Cómo se comporta nuestro modelo 1D A5 frente a *DTCNet* (3D) en cada dedo individual?

Sujeto (Modelo)	Pulgar	Índice	Medio	Anular	Meñique	Media
S1 — A5 vs. *DTCNet*	0.6135/0.69	**0.7909**/0.76	0.6320/0.76	0.7188/0.74	**0.6061**/0.60	0.6723/0.71
S2 — A5 vs. *DTCNet*	**0.6241**/0.62	0.6087/0.67	0.4107/0.52	**0.6280**/0.56	0.4733/0.58	0.5490/0.59
S3 — A5 vs. *DTCNet*	**0.8367**/0.82	**0.7487**/0.73	0.6798/0.72	**0.8137**/0.81	**0.8190**/0.77	**0.7796**/0.77
Media A5 vs. *DTCNet*	0.6914/0.70	0.7161/0.72	0.5742/0.67	**0.7202/0.70**	0.6328/0.65	0.6669/0.69
Diferencia (Δr)	-0.0086	-0.0039	$-\mathbf{0.0958}$	$+\mathbf{0.0202}$	-0.0172	-0.0231

Fuente: Creación propia a partir de [19] y el repositorio GitHub [21].

Hallazgo Clave de la Comparación en las 15 Celdas

A5 **supera a *DTCNet* [19] en 8 de los 15 pares sujeto-dedo**, en la media del **Sujeto 3** (0.7796 **vs.** 0.77) y en el promedio global del **dedo Anular** ($+0.0202$). Más del $\mathbf{83}\ \%$ de la brecha global proviene exclusivamente del dedo Medio (-0.0958).

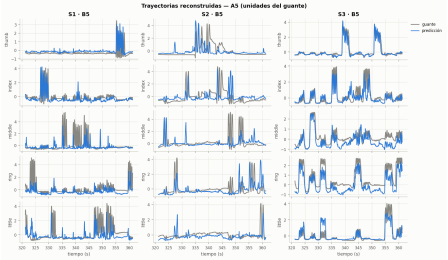


Figura A.17. Reconstrucción de A5 en B5. **Fuente:** Obtenida de GitHub [21].

Volver al Índice Extra

Anexo A19: Matriz Completa de Trazabilidad Computacional (Archivos CSV)

Pregunta del jurado: ¿De qué archivo exacto proviene cada cifra reportada en el documento y en las diapositivas?

Archivo CSV de Respaldo	Contenido Experimental Auditado (Sección 9)
`results_subjects.csv`	Medias por sujeto en ablaciones (época 50, `A0-A5`, `P0-P5`).
`results_all.csv`	Resultados por pliegue, sujeto y dedo en ablaciones.
`history_A5b / history_A5.csv`	Curvas train/val época por época (1–50).
`paired_deltas[_summary].csv`	Deltas apareados por pliegue (`A0` $\rightarrow$ `A5`, $14/15$ $+$).
`summary/ablation_retrospective.csv`	Simulación retrospectiva de checkpoint ($0.6837 \rightarrow 0.7330$).
`summary/tpe_trials / tpe_folds.csv`	Historial de los 96 trials TPE y métricas por fold/parámetros.
`summary/tpe_comparison.csv`	Descomposición entre época 50, checkpoint y TPE.
`summary/tpe_verification.csv`	Verificación multi-semilla (60 runs: `A5` 0.7372 vs. `A5b` 0.7112).
`summary/tpe_selected_models.csv`	Hiperparámetros ganadores y mediana de época ($21, 32, 28$).
`summary/tpe_verification_paired*.csv`	Contrastes apareados en verificación (`S2` $+0.0319$).
`summary/tpe_test[_summary].csv`	Test Oficial por semilla, sujeto y dedo ($r = 0.6669$).
`summary/tpe_test_protocols.csv`	Comparación `b1b4_es_b5` (0.6333) vs. `b1b5_fixed` (0.6669).

Fuente: Creación propia a partir de los registros del repositorio GitHub [21].

6 Reglas Oficiales de Cálculo

1. **Precisión completa:** Toda media se calcula en coma flotante antes de redondear a 4 decimales.
2. **Jerarquía:** 5 dedos $\rightarrow$ pliegue/semilla $\rightarrow$ sujeto $\rightarrow$ media global.
3. **Trayectoria completa:** Pearson medido tras *overlap-add*, nunca en ventanas sueltas.
4. **Deltas apareados:** Δr calculado sin redondear (± 0.0001).
5. **Verificación limpia:** Excluye la semilla de búsqueda.
6. **Cero edición manual:** Exportación directa desde scripts.

Volver al Índice Extra

Anexo A20: Gobernanza de Datos Biomédicos y Poda Estructurada (Trabajo Futuro)

Pregunta del jurado: ¿Cómo se cumple el manejo de datos sensibles y cómo reducir el tamaño (9.35–28.03 M) para un sistema embebido?

1. Gobernanza y Anonimización de Datos Clínicos

- **Benchmark público internacional:** Se utilizó exclusivamente el corpus *BCI Competition IV — Dataset 4* [1], recolectado en el *Harborview Medical Center* (University of Washington).
- **Anonimización de origen:** Los registros ECoG se distribuyen desprovistos de metadatos personales (`sub1`, `sub2`, `sub3`), cumpliendo con los protocolos internacionales de privacidad biomédica.

2. Formulación Proyectiva de Poda Estructurada (Trabajo Futuro)

Para comprimir las capas profundas ($4f$ y $8f$) de `A5` hacia hardware neuroprotésico de bajo consumo, se plantea como **propuesta matemática de trabajo futuro** evaluar la importancia de cada filtro $o \in \{1, \ldots, C_{\text{out}}\}$ mediante la norma ℓ_1 y el factor de escala γ_o de `LayerNorm`:

$$\mathcal{I}_{\ell_1}(o) = \sum_{c=1}^{C_{\text{in}}} \sum_{m=1}^{k} |W_{o,c,m}|, \qquad \mathcal{I}_{\text{LN}}(o) = |\gamma_o| \cdot \|\mathbf{W}_{o,:,:}\|_2$$

eliminando físicamente los canales con menor contribución antes de reentrenar (*fine-tuning*) o destilar hacia un modelo estudiante ligero [21].

Volver al Índice Extra